Nevizuálne snímanie obsadenosti uzavretých priestorov: prehľad metód s ohľadom na ochranu súkromia a odolnosť v kritických podmienkach*

Oliver Pribula Lukáš Poláček Martin Pivko
Daniil Romashov

Slovenská technická univerzita v Bratislave
Fakulta informatiky a informačných technológií
xpribula@stuba.sk, xpivko@stuba.sk, xpolacek@stuba.sk, xromashov@stuba.sk

1. novembra 2026

Abstrakt

Údaje o tom, koľko ľudí sa nachádza v miestnosti, potrebujú rôzne odvetvia, napr. správcovia budov na riadenie vykurovania a vetrania, prevádzkovatelia služieb na informovanie zákazníkov a záchranné zložky pri rôznych katastrofických situáciách. Najrozšírenejším zdrojom tohto údaja sú kamery, tie však zaznamenávajú identitu osôb, a pri tom v tme alebo v dyme zlyhávajú. Článok prináša prehľad nevizuálnych metód zisťovania obsadenosti pomocou environmentálnych senzorov, nízkorozlíšených termálnych polí, snímania pomocou Wi-Fi, radarov v pásme milimetrových vĺn a aktívneho akustického snímania, a porovnáva ich z hľadiska presnosti odhadu počtu osôb, ochrany ich súkromia, odolnosti v zhoršených podmienkach a ceny. Prehľad vychádza z rešerše v databázach IEEE Xplore a Web of Science za roky 2018 až 2026. Ukazujeme, že žiadna z možností sama nespĺňa všetky požiadavky a že absencia kamery ešte nezaručuje anonymitu, pretože rádiové signály aj nízkorozlíšené termálne obrazy nesú biometrické vzory a rádiový kanál môže odpočúvať aj tretia strana. Na základe prehľadu navrhujeme koncept systému NOISE, ktorý kombinuje rádiofrekvenčné a termálne snímanie s adaptívnym váhovaním modalít a spracúvava údaje priamo v zariadení. Záver článku sumarizuje otvorené problémy, ktorými sa bude projekt ďalej zaoberať.

1 Úvod

Obsadenosť priestoru, teda informácia o tom, koľko ľudí sa v ňom nachádza, je vstupom pre množstvo rozhodnutí. V budovách podľa nej možno riadiť vykurovanie, vetranie a klimatizáciu tak, aby sa neplytvalo energiou v prázdnych miestnostiach a aby v plných miestnostiach nebolo vydýchané [3]. Prevádzkovatelia fitness centier, knižníc či reštaurácií ju môžu zobrazovať zákazníkom. V krízovej situácii, napríklad pri požiari, je rovnaký údaj otázkou života, napri. veliteľ zásahu potrebuje vedieť, kde v budove zostali ľudia.

*Semestrálny projekt v predmete Metódy inžinierskej práce, ak. rok 2026/27, vedenie: Ing. Robert Marko, PhD.

Súčasné riešenia majú 2 skupiny nedostatkov. Kamerové systémy dokážu ľudí spočítať presne, ale zaznamenávajú ich identitu. Ich nasadenie v kanceláriách, šatniach alebo ubytovacích priestoroch naráža na legislatívu o ochrane osobných údajov [10] aj na odpor samotných ľudí. Navyše optické snímanie prestáva fungovať práve v situáciách, keď je údaj najcennejší, v tme a v dyme. Druhú skupinu tvoria riešenia vyžadujúce spoluprácu ľudí, napríklad registrácia pri vstupe alebo mobilná aplikácia. Tie poskytujú neúplné údaje, lebo ich ľudia nepoužívajú dôsledne, a v kríze sú nepoužiteľné.

Tento článok sa zaoberá otázkou, či sa dá počet osôb v uzavretej miestnosti spoľahlivo zistiť bez toho, aby sme ich videli. K téme nás primárne usmernil prehľad systémov merania obsadenosti budov od Suna a kol. [35], ktorý triedi existujúce prístupy podľa typu senzora a upozorňuje na napätie medzi presnosťou a ochranou súkromia. Oproti nemu kladieme dôraz na dve požiadavky, ktoré sa v literatúre riešia oddelene, a to konrétne anonymitu v bežnej prevádzke a funkčnosť v kritických podmienkach.

Článok je organizovaný nasledovne. V časti 2 definujeme úlohu, požiadavky na jej riešenie a postup rešerše. Časť 3 prináša prehľad nevizuálnych modalít a časť 4 ich porovnanie spolu s prehľadom prístupov k fúzii. V časti 5 ukazujeme, prečo nevizuálne snímanie automaticky neznamená anonymitu. Časť 6 sa venuje správaniu senzorov v dyme a pri požiari. V časti 7 opisujeme koncept systému NOISE, ktorý z prehľadu vychádza. Časť 8 uzatvára článok a sumarizuje otvorené problémy.

2 Úloha, požiadavky a postup rešerše

V literatúre sa pod pojmom obsadenosť rozumejú úlohy rôznej náročnosti [5, 35]. Najjednoduchšou je *detekcia prítomnosti*, teda rozhodnutie, či je miestnosť prázdna. Náročnejší je *odhad počtu* osôb a najnáročnejšia je *lokalizácia*, teda určenie, kde sa osoby nachádzajú, prípadne sledovanie ich pohybu. Pre riadenie budovy často postačí prítomnosť alebo hrubý počet, pre zobrazenie vyťaženosti služby je potrebný počet a pre záchranárov je užitočná aj približná poloha.

Pre účely tohto prehľadu hodnotíme metódy podľa štyroch kritérií:

1. **Presnosť odhadu počtu** - či metóda dokáže rozlíšiť počet osôb, nielen prítomnosť, a ako sa jej presnosť mení s rastúcim počtom osôb.
2. **Ochrana súkromia** - či z údajov, ktoré metóda zaznamenáva, možno identifikovať konkrétnu osobu alebo odvodiť citlivé informácie o nej.
3. **Odolnosť v zhoršených podmienkach** - či metóda funguje v tme, v dyme a pri zvýšenej teplote.
4. **Cena a nasaditeľnosť** - cena hardvéru, nároky na inštaláciu a kalibráciu v novej miestnosti.

Dôležitou požiadavkou je, aby metóda nevyžadovala *spoluprácu* osôb, teda aby nemuseli nosiť žiadne zariadenie ani vykonávať žiadnu akciu. Takéto snímanie sa označuje ako bezkontaktné alebo bez zariadenia (angl. *device-free*).

Postup rešerše. Okrem primárneho zdroja [35] a starších základných prác sme literatúru vyhľadávali v databázach IEEE Xplore a Web of Science Core Collection s obmedzením na roky 2018 až 2026. Dopyty pokrývali šesť okruhov: odhad počtu osôb pomocou CSI, radaru a termálnych polí; fúziu modalít; detekciu osôb v dyme

a pri záchranných akciách; súkromie a identifikáciu osôb z rádiových signálov; akustické snímanie; a spracovanie na mikrokontroléroch. Z 792 exportovaných záznamov zostalo po odstránení duplikátov medzi databázami 682. Na základe názvov a abstraktov sme vylúčili práce mimo uzavretých priestorov (parkoviská, drony, kabíny vozidiel) a práce založené na kamerách a z ostatných sme vybrali tie, ktoré uvádzajú experimentálne overenie alebo súhrnný pohľad na niektoré z našich kritérií. Číselné výsledky citovaných prác preberáme z ich abstraktov; boli namerané v rôznych podmienkach, preto ich nemožno priamo porovnávať.

3 Prehľad nevizuálnych modalít

3.1 Environmentálne a pohybové senzory

Najlacnejšou skupinou sú senzory, ktoré sú v budovách často už nainštalované. Pasívne infračervené (PIR) senzory pohybu reagujú na zmenu tepelného žiarenia v zornom poli, preto spoľahlivo zachytia vstup osoby do miestnosti, no nezachytia osobu, ktorá sedí alebo leží bez pohybu. Počet osôb z nich priamo zistiť nemožno [35].

Koncentrácia oxidu uhličitého v miestnosti rastie s počtom osôb, ktoré dýchajú. Jin a kol. [18] ukázali, že s využitím fyzikálneho modelu šírenia CO_2 vo vetranej miestnosti možno obsadenosť odhadovať presnejšie než čisto štatistickými metódami. Chitnis a kol. [6] však na verejnom súbore údajov z kancelárskej budovy dosiahli z CO_2, teploty a vlhkosti presnosť detekcie prítomnosti len 66-82 % a presnosť odhadu úrovne či počtu 69-80 %; modely založené na jedinom environmentálnom senzore pritom zaostávali za kombináciou senzorov. Princíp má aj prirodzené obmedzenia: koncentrácia sa mení pomaly, závisí od vetrania a otvárania okien a v priestore zasiahnutom požiarom je CO_2 produktom horenia, takže prestáva niesť informáciu o ľuďoch. Environmentálne senzory sú teda vhodné ako doplnkový zdroj, nie ako jediný.

3.2 Nízkorozlíšené termálne polia

Termálne polia (angl. *thermopile array*) merajú teplotu v mriežke s nízkym rozlíšením, typicky 8×8 až 32×24 bodov. Ľudské telo sa v takom obraze prejaví ako škvrna vyššej teploty, ale tvár ani postava nie sú rozpoznateľné. Beltran a kol. [4] v systéme ThermoSense spojili termálne pole 8×8 so senzorom pohybu a odhadovali počet osôb na účely riadenia vykurovania a klimatizácie. Výhodou je, že senzor zachytí aj nehybnú osobu a spracovanie je výpočtovo nenáročné. Rinta-Homi a kol. [31] systematicky skúmali, ako nízko možno ísť s rozlíšením: spoľahlivú detekciu prítomnosti dosiahli už pri rozlíšení 4×2 bodov, ak snímková frekvencia neklesla pod 4 snímky za sekundu, a výsledky boli citlivé na uhol pohľadu senzora. Nižšie rozlíšenie pritom znamená menej informácie o identite osôb aj nižšiu cenu.

Obmedzenia vyplývajú z fyzikálneho princípu. Termálne pole meria rozdiel teplôt medzi človekom a pozadím; keď sa teplota okolia priblíži k teplote povrchu tela, kontrast zaniká. Prekážkou sú aj iné zdroje tepla (radiátory, notebooky, horúce nápoje) a vzájomné zakrývanie osôb, keď sa dve škvrny spoja do jednej. Papanashi a kol. [27] statické zdroje tepla odlišujú od ľudí podľa toho, či škvrna v čase vykazuje mikropohyby, a celé spracovanie vrátane sledovania osôb vykonávajú na mikrokontroléri ESP32 s 520 kB SRAM. Risso a kol. [32] ukázali, že automatizovaným návrhom architektúry neurónovej siete a kvantizáciou možno počítanie osôb z infračerveného poľa

na mikrokontroléri zrýchliť a zúsporniť, pri rovnakej presnosti až 15-násobne nižšou spotrebou energie.

3.3 Snímanie pomocou Wi-Fi

Ľudské telo pozostáva prevažne z vody, preto ovplyvňuje šírenie rádiových vĺn: tieni priamu cestu medzi vysielačom a prijímačom a vytvára nové odrazy. Wi-Fi snímanie využíva túto vlastnosť a nevyžaduje žiadny špeciálny vysielač, postačuje komunikácia bežných zariadení [34].

Najjednoduchšou veličinou je intenzita prijímaného signálu (RSSI). Depatla a kol. [9] ukázali, že už z meraní intenzity medzi jedným párom vysielača a prijímača možno odhadnúť počet osôb, ak sa vhodne modeluje tienenie priamej cesty a rozptyl signálu na ľuďoch. Bohatšiu informáciu poskytuje kanálová informácia (angl. *Channel State Information*, CSI), ktorá opisuje amplitúdu a fázu signálu na každej z podnosných frekvencií. Ma a kol. [23] v prehľade opisujú, ako sa CSI využíva na detekciu prítomnosti, rozpoznávanie aktivít aj odhad počtu osôb, a zhŕňajú typický reťazec spracovania: odstránenie šumu, extrakciu príznakov a klasifikáciu. Xi a kol. [40] využili pozorovanie, že variabilita CSI rastie s počtom pohybujúcich sa osôb, a na tomto princípe navrhli metódu počítania davu. Zou a kol. [44] v systéme WiFree získavali CSI priamo z bežných smerovačov a v troch miestnostiach rôznej veľkosti uvádzajú presnosť 99,1 % pri detekcii prítomnosti a 92,8 % pri odhade počtu osôb.

Väčšina metód stavia na pohybe, ktorý mení kanál. Sediaci ľudia sa však tiež nehýbu úplne: Korany a Mostofi [19] ukázali, že drobné pohyby pri sedení (posunutie sa na stoličke, prekríženie nôh) nesú informáciu o počte osôb, a ich štatistickým modelom odhadli počet až 10 sediacich ľudí s chybou najviac jednej osoby v 96,3 % prípadov, cez stenu v 90 % prípadov.

Hlavným problémom Wi-Fi snímania je závislosť od prostredia. Model naučený v jednej miestnosti nemusí fungovať v inej, ba ani v tej istej po presunutí nábytku, pretože sa zmení viaccestné šírenie signálu [23]. Santos a kol. [33] zbierali CSI tri mesiace v rôznych miestnostiach a model natrénovaný bez údajov z cieľového prostredia v ňom fungoval zreteľne horšie; doplnenie časti údajov z cieľového prostredia zvýšilo presnosť klasifikácie približne o 16–20 %. Na zníženie kalibrácie sa preto skúma učenie z malého počtu príkladov: metóda DASECount [15] sa prispôsobí novému prostrediu už z piatich označených vzoriek na triedu a pri počítaní 0–8 osôb uvádza priemernú presnosť 96,4 %. Signál tiež ovplyvňujú susedné siete a ľudia za stenou.

3.4 Radary v pásme milimetrových vĺn

Radary s frekvenčne modulovanou nosnou vlnou (FMCW) merajú vzdialenosť, rýchlosť a uhol odrazených objektov. V pásme 60-80 GHz, teda pri vlnových dĺžkach okolo 4-5 mm, dosahujú rozlíšenie v rádoch centimetrov a sú komerčne dostupné ako lacné jednočipové moduly. Zhao a kol. [43] použili radar v tomto pásme na súčasné sledovanie viacerých osôb v miestnosti. Rádiové snímanie zachytí aj veľmi jemné pohyby: Adib a kol. [1] merali FMCW rádiom dýchanie a tep viacerých ľudí naraz bez akéhokoľvek kontaktu. Pre úlohu obsadenosti je to podstatné, lebo vďaka tomu možno odlíšiť nehybného človeka od predmetu – človek dýcha. Tento princíp využili Weiss a kol. [38]: kandidátov na osoby nájdených v spektre vzdialeností overovali podľa prítomnosti vitálnych funkcií a s radarom 60 GHz dosiahli v kancelárii s 0-4 osobami presnosť ± 1 osoba v 85,4 % prípadov. Systém MMCOUNT [16] kombinuje dýchanie

a drobné pohyby a v poslucháreni, triede aj zasadačke počítal sediace osoby s presnosťou až 95,8 %, a to aj pri vzájomnej vzdialenosti osôb 0,4 m.

Radar je oproti Wi-Fi menej závislý od usporiadania miestnosti, pretože meria priamo polohu odrazov. Jeho dosah je však obmedzený zorným poľom antény a pri väčšom počte blízko stojacich ľudí sa odrazy prekrývajú. Ren a kol. [30] sa zaoberali práve skupinami osôb, ktoré sú bližšie pri sebe, než je rozlišovacia schopnosť radaru, a kombinovali sledovanie skupiny s klasifikátorom počtu osôb v nej. Ani radar nie je úplne nezávislý od prostredia: modely naučené pri jednom usporiadaní odrazov od okolitých predmetov sa podobne ako pri Wi-Fi musia prispôsobovať novým miestnostiam. Výpočtová náročnosť naopak prekážkou nie je, Mach a kol. [24] spustili kvantizovanú konvolučnú sieť na počítanie až 10 osôb z ultraširokopásmového radaru na mikrokontroléroch STM32 s časom inferencie pod 48 ms.

3.5 Akustické snímanie

Aktívne akustické snímanie vysiela zvukový signál v nepočuteľnom pásme a vyhodnocuje jeho odrazy, podobne ako sonar. Nandakumar a kol. [25] ukázali, že už bežný smartfón dokáže z odrazov nepočuteľného signálu vyslaného reproduktorom sledovať dýchacie pohyby spiaceho človeka. Altinses a Schwung [2] použili aktívny sonar priamo na odhad obsadenosti miestnosti s argumentom, že optické senzory v dyme zlyhávajú; ich model kombinuje Sabinovu teóriu dozvuku s neurónovou sieťou a v troch prostrediach dosiahol presnosť detekcie 84,5 %. Výhodou je nízka cena reproduktora a mikrofónov. Pre počítanie osôb v celej miestnosti je však akustické snímanie citlivé na hluk a ozvenu a mikrofón v zariadení vyvoláva obavy o súkromie. Tie sú opodstatnené: Williams a kol. [39] odhadovali počet hovoriacich osôb z pasívne zaznamenaného zvuku a ani po náhodnom narušení zvukových rámcov, ktoré skrylo obsah reči, nedokázali úplne zabrániť rozpoznaniu hovoriacich. Túto modalitu v projekte považujeme za doplnkovú, v aktívnom režime bez záznamu reči, a jej prínos ešte overíme.

4 Porovnanie modalít

Tabuľka 1 zhŕňa porovnanie modalít podľa kritérií z časti 2. Hodnotenie je kvalitatívne a vychádza z prehľadov [5, 23, 34, 35], z prác uvedených v časti 3 a z fyzikálnych princípov. Kameru uvádzame ako referenciu. Tabuľka 2 dopĺňa vybrané kvantitatívne výsledky z rešerše.

Tabuľka 1: Kvalitatívne porovnanie modalít (●●● = najlepšie)

Modalita	Odhad počtu	Súkromie	Tma a dym	Nízka cena
Kamera (optická)	●●●	●	●	●●
PIR senzor pohybu	●	●●●	●●	●●●
Senzor CO_2	●	●●●	●	●●
Termálne pole	●●	●●●	●●	●●
Wi-Fi CSI	●●	●●	●●●	●●●
mmWave radar	●●●	●●	●●●	●●
Akustické snímanie	●●	●	●●●	●●●

Z porovnania vyplývajú dve pozorovania. Po prvé, žiadna modalita nedosahuje najlepšie hodnotenie vo všetkých kritériách. Rádiové metódy sú najodolnejšie voči zhorše-

Tabuľka 2: Vybrané výsledky z rešerše (údaje z abstraktov; podmienky meraní sa líšia, hodnoty nie sú priamo porovnateľné)

Práca	Modalita	Úloha a uvádzaný výsledok
WiFree [44]	Wi-Fi CSI	počet osôb v 3 miestnostiach, presnosť 92,8 %
Korany a Mostofi [19]	Wi-Fi CSI	až 10 sediacich osôb, chyba ≤ 1 v 96,3 % (cez stenu 90 %)
DASECount [15]	Wi-Fi CSI	0-8 osôb v novom prostredí z 5 vzoriek na triedu, priemerne 96,4 %
Weiss a kol. [38]	radar 60 GHz	0-4 osoby, overenie vitálnych funkcií, ± 1 v 85,4 %
MMCOUNT [16]	mmWave radar	sediace osoby, presnosť do 95,8 %
Mach a kol. [24]	UWB radar	do 10 osôb, 98,2 % po kvantizácii, MCU STM32
Rinta-Homi a kol. [31]	termálne pole	prítomnosť spoľahlivo už pri 4×2 bodoch a ≥ 4 snímkach/s
Papanashi a kol. [27]	termálne pole	počet a sledovanie osôb celé na ESP32 (520 kB SRAM)
Altinses a Schwung [2]	aktívny sonar	obsadenosť v 3 prostrediach, presnosť 84,5 %
Chitnis a kol. [6]	CO_2, teplota, vlhkosť	prítomnosť 66-82 %, úroveň alebo počet 69-80 %

nej viditeľnosti, termálne pole má najlepšiu vrodenú anonymitu (s výhradou uvedenou v časti 5) a environmentálne senzory sú najlacnejšie, ale najmenej presné. Po druhé, slabiny jednotlivých modalít sa nekryjú: termálne pole zlyháva pri vysokej teplote, keď rádiové snímanie funguje ďalej, a Wi-Fi zlyháva pri rádiovom rušení, ktoré termálne pole neovplyvní. To naznačuje, že vhodná kombinácia modalít môže prekonať každú z nich samostatne.

Fúzia modalít. Literatúra túto domnienku podporuje, hoci väčšinou pri iných kombináciách senzorov, než aké uvažujeme my. Hobson a kol. [14] spájali v kancelárskej budove údaje, ktoré už existovali, konkrétne počty zariadení pripojených k Wi-Fi, CO_2, PIR a spotrebu elektriny a samotné počty Wi-Fi zariadení vysvetľovali počas obsadených hodín 80–83 % rozptylu skutočného počtu osôb. Rafi a kol. [29] navrhli fúziu, ktorá každému senzoru priraďuje váhu podľa podmienok v miestnosti, a uvádzajú presnosť odhadu počtu 94 %, o 3 percentuálne body viac než porovnávané metódy. Cui a Zheng [7] riešili opačný problém, energetickú náročnosť: ich rámec E-M2 počas behu vypína modality, ktoré v danej chvíli neprinášajú novú informáciu, a príležitostne ich opäť zapína, čím znížil spotrebu v priemere o 40,8 % bez straty presnosti. Prácu, ktorá by na počítanie osôb v budove spájala práve rádiové a termálne senzory s váhami odvodenými od kvality signálu, sme v prehľadaných záznamoch nenašli, najbližšie k nej majú práce o detekcii osôb v dyme (časť 6).

5 Nevizuálne neznamená anonymné

Bežný argument v prospech nevizuálnych senzorov je, že nezaznamenávajú tvár, a teda chránia súkromie. Tento argument je však neúplný. Nariadenie GDPR [10] sa nevzťa-

huje len na fotografie, ale na akékoľvek údaje, z ktorých možno fyzickú osobu identifikovať, a osobitne chráni biometrické a zdravotné údaje.

Viaceré práce ukazujú, že rádiové signály takúto informáciu nesú. Wang a kol. [37] rozpoznávali ľudí podľa chôdze len z CSI bežnej Wi-Fi siete. Zhao a kol. [43] pomocou mmWave radaru osoby nielen sledovali, ale aj rozlišovali, kto je kto, na základe tvaru ich odrazov. Systém MU-ID [42] s jedným komerčným radarom identifikoval jednu osobu podľa chôdze s presnosťou až 97 % a až štyri súčasne kráčajúce osoby s presnosťou nad 92 %. Gonzalez a kol. [11] z radarových mračien bodov počas chôdze odhadovali výšku, hmotnosť, pohlavie aj obvod pása, s presnosťou do 82 %. Systém Vital-Radio [1] meria dýchanie a tep, teda údaje, ktoré majú zdravotný charakter. Ani termálne polia nie sú voči identifikácii imúnne: Jiang a kol. [17] z lacných termálnych polí rozpoznávali osoby podľa chôdze s priemernou presnosťou 87,3 %. Z toho vyplýva, že ochranu súkromia nemožno odvodiť len od typu senzora; záleží aj od rozlíšenia a od toho, čo sa so surovými údajmi deje [31].

Za kľúčové preto považujeme *miesto spracovania*. Ak surové signály opustia senzor a ukladajú sa na server, vzniká databáza, z ktorej by sa dali identifikačné vzory dodatočne vyťažiť. Ak sa naopak všetko spracuje priamo v zariadení a von odchádza iba agregovaný údaj, počet osôb, identifikácia je obmedzená samotnou architektúrou. Výpočet na hrane, teda priamo na mikrokontroléri senzora, je dnes realistický: rámce ako TensorFlow Lite Micro [8] umožňujú spúšťať kvantizované neurónové siete na zariadeniach s pamäťou v rádoch stoviek kilobajtov a práce uvedené v časti 3 ukazujú počítanie osôb z termálneho poľa aj z radaru priamo na mikrokontroléri [24, 27, 32].

Spracovanie v zariadení však nerieši všetko. Wi-Fi snímanie využíva signál, ktorý sa šíri aj mimo miestnosti, a ten môže zachytiť ktokoľvek v dosahu. Hernandez a Bulut [13] ukázali, že útočník s obmedzeným prístupom k budove dokáže z CSI zachyteného cez stenu zistiť prítomnosť osôb aj smer ich pohybu. Xiao a kol. [41] využili nešifrované rámce so spätnou väzbou na tvarovanie zväzku (angl. *beamforming feedback*), ktoré bežne vysielajú Wi-Fi zariadenia, a obsadenosť miestnosti zisťovali zo vzdialenosti 20 m. Ako obranu sa navrhuje úmyselne skresľovať vysielané signály tak, aby odpočúvajúci odvodil nepravdivý počet osôb či dychovú frekvenciu [12]. Osenstätter a Krempel [26] na základe viac ako 60 publikácií triedia schopnosti Wi-Fi snímania do piatich tried a priraďujú im povinnosti podľa GDPR; konštatujú, že systémy rozpoznávajúce aktivity a identitu osôb s presnosťou nad 90 % už nie sú len teoretickou hrozbou. Pre návrh NOISE z toho plynie, že vlastný kanál senzora treba považovať za potenciálne odpočúvaný a že vysielanie Wi-Fi rámcov iba na účely snímania by sa malo obmedziť na nevyhnutnú mieru.

6 Snímanie v kritických podmienkach

Väčšina prác o obsadenosti predpokladá bežnú prevádzku budovy. Pri požiari sa však podmienky menia zásadne a každá modalita reaguje inak. Experimentálnych prác, ktoré by skúmali počítanie osôb v dyme, je málo; veľká časť prác z nášho dopytu o dyme a záchranných akciách sa venuje detekcii jednotlivých osôb termokamerami z dronov alebo hľadaniu ľudí pod troskami, nie trvalo nainštalovaným senzorom v miestnosti. Nasledujúce úvahy preto vychádzajú čiastočne z fyzikálnych princípov a v projekte ich chceme overiť meraním.

Optické snímanie zlyháva už pri miernom zadymení, pretože častice dymu rozptyľujú viditeľné svetlo. **Termálne snímanie** v dlhovlnnom infračervenom pásme preniká dymom lepšie, preto ho hasiči využívajú vo forme termokamier. Tsai a kol. [36]

s termokamerou vyhovujúcou normám pre hasičov a detektorom YOLOv4 lokalizovali osoby v zadymenom priestore s presnosťou nad 95 %. Lacné termálne polia však majú obmedzený merací rozsah a pri teplote okolia blízkej teplote tela strácajú kontrast; v blízkosti ohniska tak prestávajú byť použiteľné. **Rádiové vlny** s vlnovou dĺžkou v milimetroch až centimetroch sú oveľa dlhšie ako častice dymu, preto ich dym prakticky neovplyvňuje. Liu a kol. [22] to potvrdzujú v prostredí s prachom a v banských tuneloch: radar v testovaných scenároch stabilne detegoval chodcov aj vtedy, keď kamera a LiDAR zlyhali. Park a kol. [28] s rovnakým odôvodnením, kamery a infračervené senzory v dyme a pri tepelnom šume strácajú presnosť, nasadili na štadióne 14 radarov 60 GHz na lokalizáciu osôb pre potreby záchranných zložiek a počas 60-dňovej prevádzky dosiahli dostupnosť systému 99,96 %. Kulhandjian a kol. [20] spojili mikrodopplerovský radar s infračervenou kamerou a v hustom dyme uvádzajú presnosť detekcie osoby 98 % na validačných údajoch.

Rádiové snímanie je teda kandidátom na hlavný zdroj informácie v havarijnom režime, má však dve slabiny. Požiar môže poškodiť Wi-Fi infraštruktúru budovy; radar, ktorý si signál vysiela sám, je od nej nezávislý. Druhou slabinou je, že kanál ovplyvňuje aj samotný oheň: Li a kol. [21] pozorovali, že plameň mení amplitúdu CSI a výrazne zvyšuje jej rozptyl, a navrhli to využiť na detekciu požiaru. Model počítania osôb naučený v bežnej prevádzke by takúto zmenu mohol nesprávne interpretovať ako pohyb ľudí. To je ďalší argument, aby sa v havarijnom režime menilo aj váhovanie modalít, nielen ich napájanie.

Osobitne dôležitý je prípad *nehybnej osoby*. Človek, ktorý stratil vedomie, sa nepohybuje, a metódy založené na zmenách signálu ho môžu prehliadnuť. Práve preto je schopnosť zachytiť dýchanie [1, 38] pre havarijný režim podstatnejšia než presný počet osôb.

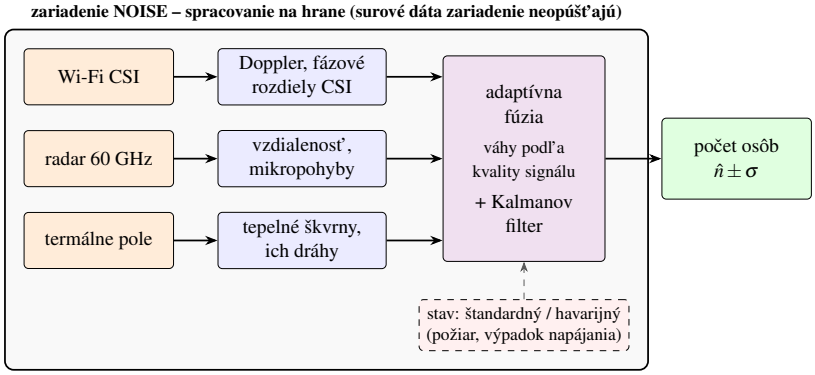
Kritické podmienky kladú nároky aj na samotné zariadenie: pri výpadku elektriny musí fungovať z batérie a pri hroziacom poškodení by malo priebežne odosielať posledný známy stav.

7 Koncept systému NOISE

Z predchádzajúcich častí vyplývajú tri požiadavky na návrh, konkrétne kombinovať modality, ktorých slabiny sa nekryjú. Ďalej spracúvavať údaje priamo v zariadení. A prispôsobiť správanie stavu prostredia. Na týchto zásadách stavia náš návrh systému NOISE (obr. 1).

Modul obsahuje mikrokontrolér s podporou zberu CSI, radar v pásme 60 GHz a termálne pole. Výber zodpovedá porovnaniu v časti 4: radar je najodolnejší a zachytí dýchanie, termálne pole prináša presnosť pri malom počte osôb a vysokú vrodenú anonymitu a CSI je takmer bezplatným doplnkom. Z každej modality sa extrahujú príznaky: z CSI Dopplerovské spektrum a fázové rozdiely [23], z radaru polohy odrazov a mikropohyby vrátane dýchania [16, 38], z termálneho poľa počet a dráhy tepelných škvŕn, pričom statické zdroje tepla sa vylúčia podľa absencie mikropohybov [27]. Každá vetva poskytne vlastný odhad počtu osôb spolu s mierou neistoty a s ukazovateľom kvality signálu, napr. kontrastom termálneho obrazu alebo stabilitou kanála.

Jadrom návrhu je *adaptívna fúzia*. Váha každej vetvy sa mení podľa kvality jej signálu: keď kontrast termálneho poľa klesá, rozhodovanie sa presúva na rádiovú vetvu, keď je zarušená Wi-Fi, rozhoduje radar. Podobne ako pri váhovanej fúzii [29] má každá vetva svoju váhu, tú však chceme odvodzovať za behu z ukazovateľov kvality signálu, aby systém reagoval aj na náhle zmeny, ako je zadymenie alebo vplyv ohňa na



Obr. 1: Architektúra spracovania v module NOISE: tri nevizuálne modality, extrakcia príznakov, adaptívna fúzia a anonymný výstup

CSI [21]. Výsledný odhad sa časovo vyhladí Kalmanovým filtrom, aby krátkodobé výkyvy nespôsobovali skoky v hlásenom počte. Výstupom je iba počet osôb s intervalom neistoty; surové dáta zariadenie neopúšťajú (časť 5). Prispôsobenie novej miestnosti chceme riešiť doladením modelu z malého počtu označených vzoriek, podobne ako pri metódach učenia z malého počtu príkladov [15], keďže úplne bez údajov z cieľového prostredia presnosť výrazne klesá [33].

Modul pracuje v dvoch režimoch. V *štandardnom* režime je napájaný cez PoE, šetrí energiou a zložitejšie modely spúšťa len pri zmene stavu; podobný princíp selektívneho vypínania modalít znížil spotrebu v práci [7]. Do *havarijného* režimu prejde pri detekcii požiaru alebo výpadku napájania: beží na záložnej batérii, uprednostňuje radarovú vetvu a detekciu dýchajúcich nehybných osôb a častejšie odosiela svoj stav.

Merateľné ciele návrhu sme stanovili takto: v miestnostiach do 15 osôb dosiahnuť odhad s chybou najviac ± 1 osoba v aspoň 90 % meraní, v zadymenej miestnosti zistiť prítomnosť nehybnej osoby do 30 sekúnd a celý inferenčný reťazec vtesnať do pamäte mikrokontroléra s nanajvýš 512 kB SRAM. Výsledky z rešerše naznačujú, že ciele sú náročné, ale nie nereálne: presnosť ± 1 osoba v 90 až 96 % prípadov dosiahli doteraz jednotlivé modality pri menšom počte osôb [19] a spracovanie termálneho poľa sa už zmestilo do mikrokontroléra s 520 kB SRAM [27]; overiť treba najmä súčasný beh troch vetiev a správanie pri 10 až 15 osobách.

8 Záver

Prehľad ukázal, že počet osôb v miestnosti možno zisťovať bez kamier viacerými spôsobmi, no každý z nich má iné slabiny: environmentálne senzory sú pomalé a nepresné [6], termálne polia strácajú kontrast pri vysokej teplote, Wi-Fi je citlivé na zmeny prostredia [33] a radar na prekrývanie odrazov [30]. Zároveň sme ukázali, že nevizuálne snímanie samo osebe nezaručuje anonymitu, lebo rádiové signály aj termálne obrazy nesú biometrické a zdravotné informácie [1, 17, 37, 42, 43] a Wi-Fi kanál môže odpočúvať aj tretia strana [13, 41]. Ochranu súkromia preto treba zabezpečiť architektúrou, konkrétne spracovaním priamo v zariadení a obmedzením toho, čo zariadenie vysiela.

Prínosom článku je zjednotenie dvoch pohľadov, ktoré sa v literatúre objavujú od-

delene, ochrany súkromia a odolnosti v krízových podmienkach, a návrh konceptu NOISE, ktorý na ne odpovedá adaptívnou fúziou modalít. Otvorené zostávajú najmä tieto otázky: ako spoľahlivo odhadovať kvalitu jednotlivých signálov za behu, ako preniesť model do novej miestnosti bez zdĺhavej kalibrácie, ako sa presnosť správa pri rastúcom počte osôb, ako oheň a horúce plyny ovplyvňujú rádiový kanál a ako sa senzory skutočne správajú v dyme a pri vysokej teplote. Pre poslednú otázku sme v rešerši nenašli verejný súbor údajov z nevizuálnych senzorov s počtom osôb v zadymenej miestnosti; odpovede na ňu aj na ostatné otázky budeme hľadať meraním na prototype.

Literatúra

[1] Fadel Adib, Hongzi Mao, Zachary Kabelac, Dina Katabi, and Robert C. Miller. Smart homes that monitor breathing and heart rate. In *Proceedings of the 33rd Annual ACM Conference on Human Factors in Computing Systems (CHI '15)*, pages 837–846. ACM, 2015.

[2] Diyar Altinses and Andreas Schwung. Residual physics-informed neural networks for robust indoor occupancy estimation using sonar. In *2026 12th International Conference on Control, Decision and Information Technologies (CoDIT)*, pages 2114–2121. IEEE, 2026.

[3] Alireza Jafarian Amiri, Kaywan Mahmoodi, Amirreza Tootchi, and Ali Razban. A review of occupancy detection techniques for HVAC control: Advances and practical challenges. *Journal of Building Engineering*, 113:113962, 2025.

[4] Alex Beltran, Varick L. Erickson, and Alberto E. Cerpa. ThermoSense: Occupancy thermal based sensing for HVAC control. In *Proceedings of the 5th ACM Workshop on Embedded Systems For Energy-Efficient Buildings (BuildSys '13)*, pages 1–8. ACM, 2013.

[5] Zhenghua Chen, Chaoyang Jiang, and Lihua Xie. Building occupancy estimation and detection: A review. *Energy and Buildings*, 169:260–270, 2018.

[6] Shubham Chitnis, Nivethitha Somu, and Anupama Kowli. Occupancy estimation with environmental sensors: The possibilities and limitations. *Energy and Built Environment*, 6(1):96–108, 2025.

[7] Jinyi Cui and Tianyue Zheng. E-M2: Efficient multimodal sensing via adaptive sensor-computation activation. *IEEE Transactions on Mobile Computing*, 25(4):4551–4565, 2026.

[8] Robert David, Jared Duke, Advait Jain, Vijay Janapa Reddi, Nat Jeffries, Jian Li, Nick Kreeger, Ian Nappier, Meghna Natraj, Tiezhen Wang, Pete Warden, and Rocky Rhodes. TensorFlow Lite Micro: Embedded machine learning for TinyML systems. In *Proceedings of Machine Learning and Systems*, volume 3, pages 800–811, 2021.

[9] Saandeep Depatla, Arjun Muralidharan, and Yasamin Mostofi. Occupancy estimation using only WiFi power measurements. *IEEE Journal on Selected Areas in Communications*, 33(7):1381–1393, 2015.

[10] Európsky parlament a Rada EÚ. Nariadenie (EÚ) 2016/679 o ochrane fyzických osôb pri spracúvaní osobných údajov a o voľnom pohybe takýchto údajov (všeobecné nariadenie o ochrane údajov). Úradný vestník Európskej únie, L 119, s. 1–88, 2016.

[11] Cinthya Celina Tamayo Gonzalez, Simone Soderi, Julian Todt, Thorsten Strufe, and Mauro Conti. Inferring personal attributes with a mmWave radar. In *2025 IEEE Wireless Communications and Networking Conference (WCNC)*, pages 1–6. IEEE, 2025.

[12] Qiuye He, Edwin Yang, Song Fang, and Shangqing Zhao. Revisiting wireless breath and crowd inference attacks with defensive deception. *IEEE/ACM Transactions on Networking*, 32(6):4976–4988, 2024.

[13] Steven M. Hernandez and Eyuphan Bulut. Adversarial occupancy monitoring using one-sided through-wall WiFi sensing. In *ICC 2021 – IEEE International Conference on Communications*. IEEE, 2021.

[14] Brodie W. Hobson, Daniel Lowcay, H. Burak Gunay, Araz Ashouri, and Guy R. Newsham. Opportunistic occupancy-count estimation using sensor fusion: A case study. *Building and Environment*, 159:106154, 2019.

[15] Huawei Hou, Suzhi Bi, Lili Zheng, Xiaohui Lin, Yuan Wu, and Zhi Quan. DASECount: Domain-agnostic sample-efficient wireless indoor crowd counting via few-shot learning. *IEEE Internet of Things Journal*, 10(8):7038–7050, 2023.

[16] Kaiyuan Hu, Hongjie Liao, Mingxiao Li, and Fangxin Wang. MMCOUNT: Stationary crowd counting system based on commodity millimeter-wave radar. In *ICASSP 2024 – 2024 IEEE International Conference on Acoustics, Speech and Signal Processing*, pages 56–60. IEEE, 2024.

[17] Hongbo Jiang, Lei Ye, Jingyang Hu, Xiaotian Chen, Siyu Chen, Wei Zhang, and Kehua Yang. WarmGait: Thermal array-based gait recognition for privacy-preserving person Re-ID. *IEEE Transactions on Mobile Computing*, 25(2):1936–1949, 2026.

[18] Ming Jin, Nikolaos Bekiaris-Liberis, Kevin Weekly, Costas J. Spanos, and Alexandre M. Bayen. Occupancy detection via environmental sensing. *IEEE Transactions on Automation Science and Engineering*, 15(2):443–455, 2018.

[19] Belal Korany and Yasamin Mostofi. Counting a stationary crowd using off-the-shelf WiFi. In *Proceedings of the 19th Annual International Conference on Mobile Systems, Applications, and Services (MobiSys '21)*, pages 202–214. ACM, 2021.

[20] Hovannes Kulhandjian, Alexander Davis, Lancelot Leong, Michael Bendot, and Michel Kulhandjian. AI-based human detection and localization in heavy smoke using radar and IR camera. In *2023 IEEE Radar Conference (RadarConf23)*, pages 1–6. IEEE, 2023.

[21] Junye Li, Aryan Sharma, Deepak Mishra, and Aruna Seneviratne. Fire detection using commodity WiFi devices. In *2021 IEEE Global Communications Conference (GLOBECOM)*, pages 1–6. IEEE, 2021.

[22] Zhenan Liu, Amir Khajepour, and George Shaker. A lightweight model-driven 4D radar framework for pervasive human detection in harsh conditions. In *2026 IEEE International Conference on Pervasive Computing and Communications Workshops (PerCom Workshops)*, pages 1–6. IEEE, 2026.

[23] Yongsen Ma, Gang Zhou, and Shuangquan Wang. WiFi sensing with channel state information: A survey. *ACM Computing Surveys*, 52(3):1–36, 2019.

[24] Tuan Kiet Tran Mach, Cong Thuong Pham, and Minhhuy Le. UWB impulse radar for people counting with convolutional neural network on microcontrollers. *IEEE Sensors Journal*, 24(9):15643–15650, 2024.

[25] Rajalakshmi Nandakumar, Shyamnath Gollakota, and Nathaniel Watson. Contactless sleep apnea detection on smartphones. In *Proceedings of the 13th Annual International Conference on Mobile Systems, Applications, and Services (MobiSys '15)*, pages 45–57. ACM, 2015.

[26] Kilian Osenstätter and Erik Krempel. ASTIV: A classification framework for privacy-respecting WiFi sensing. In *2026 IEEE European Symposium on Security and Privacy Workshops (EuroS&PW)*, pages 29–37. IEEE, 2026.

[27] Suhas Papanashi, Nishant Vasantkumar Hegde, V. Manojith Bhat, R. Bhagya, B. Roja Reddy, and Satish Patel. A lightweight, real-time human detection and tracking system for privacy-preserving occupancy monitoring using low-resolution thermal sensors. *IEEE Access*, 14:16306–16325, 2026.

[28] Dae-Seung Park, Jae-Min Choi, Ho-Jong Chang, and Chae-Seok Lee. Toward robust human detection and geo-referencing in complex indoor environments via distributed mmWave radar. *IEEE Access*, 14:109114–109141, 2026.

[29] Md. Rumman Rafi, Fei Hu, Shuhui Li, Aijun Song, Xingli Zhang, and Zheng O'Neill. Deep weighted fusion learning (DWFL)-based multi-sensor fusion model for accurate building occupancy detection. *Energy and AI*, 17:100379, 2024.

[30] Liyuan Ren, Alexander G. Yarovoy, and Francesco Fioranelli. Grouped people counting using mm-wave FMCW MIMO radar. *IEEE Internet of Things Journal*, 10(22):20107–20119, 2023.

[31] Mikko Rinta-Homi, Naser Hossein Motlagh, Agustin Zuniga, Huber Flores, and Petteri Nurmi. How low can you go? performance trade-offs in low-resolution thermal sensors for occupancy detection: A systematic evaluation. *Proceedings of the ACM on Interactive, Mobile, Wearable and Ubiquitous Technologies*, 5(3):126, 2021.

[32] Matteo Risso, Chen Xie, Francesco Daghero, Alessio Burrello, Seyedmorteza Mollaei, Marco Castellano, Enrico Macii, Massimo Poncino, and Daniele Jahier Pagliari. HW-SW optimization of DNNs for privacy-preserving people counting on low-resolution infrared arrays. In *2024 Design, Automation & Test in Europe Conference & Exhibition (DATE)*, pages 1–6. IEEE, 2024.

[33] John Dominic D. Santos, Rusty John F. Alarcon, Kenshin F. Asuncion, Catherine Janz S. Galang, Hannah Gail V. Oliveros, and Josyl Mariela R. Reyes. Investigation of environment dependence in Wi-Fi CSI-based crowd counting systems. In *TENCON 2024 – 2024 IEEE Region 10 Conference*, pages 362–365. IEEE, 2024.

[34] Reza Shahbazian and Irina Trubitsyna. Human sensing by using radio frequency signals: A survey on occupancy and activity detection. *IEEE Access*, 11:40878–40904, 2023.

[35] Kailai Sun, Qianchuan Zhao, and Jianhong Zou. A review of building occupancy measurement systems. *Energy and Buildings*, 216:109965, 2020.

[36] Pei-Fen Tsai, Chia-Hung Liao, and Shyan-Ming Yuan. Using deep learning with thermal imaging for human detection in heavy smoke scenarios. *Sensors*, 22(14):5351, 2022.

[37] Wei Wang, Alex X. Liu, and Muhammad Shahzad. Gait recognition using WiFi signals. In *Proceedings of the 2016 ACM International Joint Conference on Pervasive and Ubiquitous Computing (UbiComp '16)*, pages 363–373. ACM, 2016.

[38] Jonas Weiss, Rodrigo Perez, and Erwin Biebl. Improved people counting algorithm for indoor environments using 60 GHz FMCW radar. In *2020 IEEE Radar Conference (RadarConf20)*. IEEE, 2020.

[39] Jennifer Williams, Vahid Yazdanpanah, and Sebastian Stein. Privacy-preserving occupancy estimation. In *ICASSP 2023 – 2023 IEEE International Conference on Acoustics, Speech and Signal Processing*, pages 1–5. IEEE, 2023.

[40] Wei Xi, Jizhong Zhao, Xiang-Yang Li, Kun Zhao, Shaojie Tang, Xue Liu, and Zhiping Jiang. Electronic frog eye: Counting crowd using WiFi. In *IEEE INFOCOM 2014 – IEEE Conference on Computer Communications*, pages 361–369. IEEE, 2014.

[41] Rui Xiao, Xiankai Chen, Yinghui He, Jun Han, and Jinsong Han. Lend me your beam: Privacy implications of plaintext beamforming feedback in WiFi. In *Network and Distributed System Security Symposium (NDSS 2025)*. Internet Society, 2025.

[42] Xin Yang, Jian Liu, Yingying Chen, Xiaonan Guo, and Yucheng Xie. MU-ID: Multi-user identification through gaits using millimeter wave radios. In *IEEE INFOCOM 2020 – IEEE Conference on Computer Communications*, pages 2589–2598. IEEE, 2020.

[43] Peijun Zhao, Chris Xiaoxuan Lu, Jianan Wang, Changhao Chen, Wei Wang, Niki Trigoni, and Andrew Markham. mID: Tracking and identifying people with millimeter wave radar. In *2019 15th International Conference on Distributed Computing in Sensor Systems (DCOSS)*, pages 33–40. IEEE, 2019.

[44] Han Zou, Yuxun Zhou, Jianfei Yang, and Costas J. Spanos. Device-free occupancy detection and crowd counting in smart buildings with WiFi-enabled IoT. *Energy and Buildings*, 174:309–322, 2018.